

---

## 运动恢复结构 (SFM)

Lu Peng

School of Computer Science,  
Beijing University of Posts and Telecommunications

本课程三维重建篇所涉及的教学内容与课件参考了CS231A ,  
感谢CS231A课程团队在课程建设方面所做的工作!

---

Machine Vision Technology							
Semantic information				Metric 3D information			
Pixels	Segments	Images	Videos	Camera		Multi-view Geometry	
Convolutions Edges & Fitting Local features Texture	Segmentation Clustering	Recognition Detection	Motion Tracking	Camera Model	Camera Calibration	Epipolar Geometry	SFM
10	4	4	2	2	2	2	2

## 今日主题

---

- 运动恢复结构问题
- 欧式结构恢复
- 仿射结构恢复
- 透视结构恢复


## 今日主题

---

- 运动恢复结构问题
- 欧式结构恢复
- 仿射结构恢复
- 透视结构恢复

# 运动恢复结构问题

## Structure from Motion (sfm)

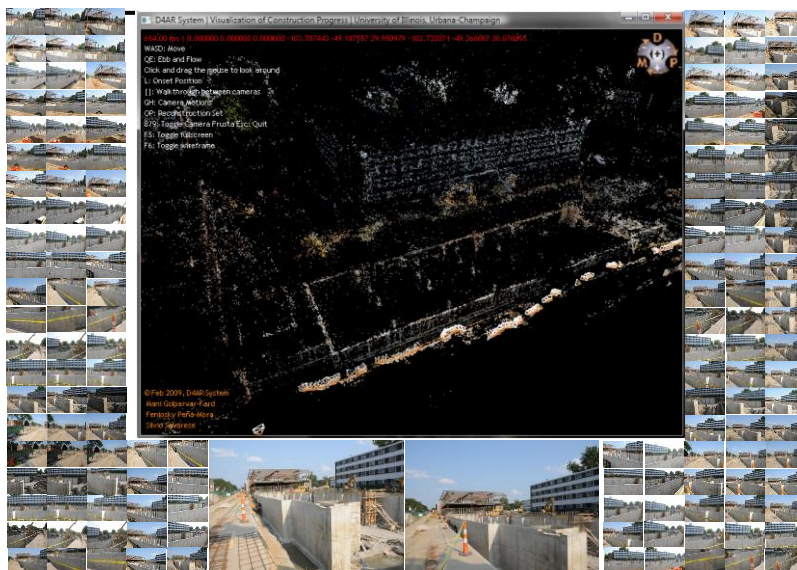


Courtesy of Oxford Visual Geometry Group

通过三维场景的多张图像，恢复出该场景的三维结构信息以及每张图片对应的摄像机参数

## 建筑场景的增量重构

Initial pair – 2168 & Complete Set 62,323 points, 160 images Golparvar-Fard, Pena-Mora, Savarese 2008



---



---



## 运动恢复结构问题

已知:  $n$  个 3D 点  $X_j$  在  $m$  张图像中的对应点的像素坐标  $x_{ij}$  ( $i = 1, \dots, m, j = 1, \dots, n$ )

且  $x_{ij} = M_i X_j$   $i = 1, \dots, m ; j = 1, \dots, n$

其中,  $M_i$  为第  $i$  张图片对应的摄像机的投影矩阵


求解:

➤  $m$  个摄像机投影矩阵  $M_i$  ( $i = 1, \dots, m$ );

运动 (motion)

➤  $n$  个三维点  $X_j$  ( $j = 1, \dots, n$ ) 的坐标。

结构 (structure)



因此, 该类问题也称为“运动恢复结构问题”!

## 三种典型的运动恢复结构任务

- 欧式结构恢复 (摄像机内参数已知, 外参数未知)
- 仿射结构恢复 (摄像机为仿射相机, 内、外参数均未知)
- 透视结构恢复 (摄像机为透视相机, 内、外参数均未知)

## 今日主题

- 运动恢复结构问题
- 欧式结构恢复
- 仿射结构恢复
- 透视结构恢复

## 欧式结构恢复问题

已知:

- $n$ 个三维点 $X_j (j = 1, \dots, n)$  在 $m$ 张图像中的对应点的像素坐标 $x_{ij}$
- $m$ 张图像对应的摄像机的内参数矩阵 $K_i (i = 1, \dots, m)$

$$\text{且} \quad x_{ij} = M_i X_j = K_i [R_i \ T_i] X_j \quad i = 1, \dots, \boxed{m}; j = 1 \dots \boxed{n}$$

$\uparrow$                        $\uparrow$   
图像个数              3D点个数

其中,  $M_i, K_i, [R_i \ T_i]$ 为第 $i$ 张图片对应的摄像机的投影矩阵、内参数及外参数矩阵

## 欧式结构恢复问题

已知:

- $n$ 个三维点 $X_j (j = 1, \dots, n)$  在 $m$ 张图像中的对应点的像素坐标 $x_{ij}$
- $m$ 张图像对应的摄像机的内参数矩阵 $K_i (i = 1, \dots, m)$

且  $x_{ij} = M_i X_j = K_i [R_i \ T_i] X_j$   $i = 1, \dots, m; j = 1, \dots, n$

↑                      ↑  
图像个数          3D点个数

其中,  $M_i$ ,  $K_i$ ,  $[R_i \ T_i]$ 为第*i*张图片对应的摄像机的投影矩阵、内参数及外参数矩阵

**求解:**

- $n$ 个三维点 $X_j(j = 1, \dots, n)$ 的坐标;
- $m$ 个摄像机的外参数  $R_i$  及  $T_i$  ( $i = 1, \dots, m$ )

## 欧式结构恢复问题

已知：

- $n$ 个三维点 $X_j (j = 1, \dots, n)$  在 $m$ 张图像中的对应点的像素坐标 $x_{ij}$
- $m$ 张图像对应的摄像机的内参数矩阵 $K_i (i = 1, \dots, m)$

且  $x_{ij} = M_i X_j = K_i [R_i \ T_i] X_j$   $i = 1, \dots, m; j = 1, \dots, n$

? ? ?
↑ ↑  
 图像个数      3D点个数

其中,  $M_i$ ,  $K_i$ ,  $[R_i \ T_i]$ 为第*i*张图片对应的摄像机的投影矩阵、内参数及外参数矩阵

**求解：**


- $n$ 个三维点 $X_j(j = 1, \dots, n)$ 的坐标;
- $m$ 个摄像机的外参数  $R_i$  及  $T_i$  ( $i = 1, \dots, m$ )

## 欧式结构恢复问题（两视图）

---

## 欧式结构恢复问题（两视图）

---





## 欧式结构恢复问题（两视图）

问题:

$$\begin{aligned}x_{1j} &= M_1 X_j = K_1 [I \quad 0] X_j \\x_{2j} &= M_2 X_j = K_2 [R \quad T] X_j\end{aligned} \quad j = 1 \dots, n$$

求解: 1. 求解基础矩阵F

归一化八点法

2. 利用F与摄像机内参数求解本质矩阵E

$$E = K_2^T F K_1$$

3. 分解本质矩阵获得R与T

$$E \rightarrow R, T$$

4. 三角化求解三维点 $X_j$ 坐标

$$X_j^* = \underset{X_j}{\operatorname{argmin}} (d(x_{1j}, M_1 X_j) + d(x_{2j}, M_2 X_j))$$

## 本质矩阵分解

$$E = [T_{\times}] R$$

找到一个策略把  $E$  因式分解为两个组成部分.....

## 本质矩阵分解

$$E = [T_{\times}]R$$

找到一个策略把  $E$  因式分解为两个组成部分.....

重要说明:

$$x_2^T F x_1 = 0 \quad \Longrightarrow \quad E = K_2^T F K_1$$

无法确定  $F$  的符号及尺度;  
 $-F$  或者  $kF$  都满足上式

所以, 也无法确定  $E$  的符号及尺度

## 本质矩阵分解

$$E = [T_{\times}]R$$

定义两个矩阵:

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad Z = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

## 本质矩阵分解

$$E = [T_{\times}]R$$

定义两个矩阵：

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad Z = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

**重要性质：** 相差一个正负号的情况下

$$Z = \text{diag}(1,1,0)W = \text{diag}(1,1,0)W^T$$

## 本质矩阵分解

$$E = [T_{\times}]R$$

定义两个矩阵：

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad Z = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

**重要性质：** 相差一个正负号的情况下

$$Z = \text{diag}(1,1,0)W = \text{diag}(1,1,0)W^T$$

$[T_{\times}]$ 可以写成： $[T_{\times}] = kUZU^T$

其中， $U$  是单位正交矩阵。

## 本质矩阵分解

$$E = [T_{\times}]R$$

定义两个矩阵：


$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad Z = \begin{bmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

**重要性质：** 相差一个正负号的情况下

$$Z = \text{diag}(1,1,0)W = \text{diag}(1,1,0)W^T$$

$[T_{\times}]$  可以写成：  $[T_{\times}] = kUZU^T$

其中， $U$  是单位正交矩阵。



不考虑符号  
、尺度

$$\begin{aligned} [T_{\times}] &= UZU^T \\ &= U\text{diag}(1,1,0)WU^T \\ &= U\text{diag}(1,1,0)W^TU^T \end{aligned}$$

## 本质矩阵分解

$$E = [T_{\times}]R$$



$$\begin{aligned} [T_{\times}] &= UZU^T \\ &= U\text{diag}(1,1,0)WU^T \end{aligned}$$

$$\begin{aligned} E &= [T_{\times}]R = (U\text{diag}(1,1,0)WU^T)R \\ &= U\text{diag}(1,1,0)(WU^TR) \end{aligned}$$

## 本质矩阵分解

$$E = [T_{\times}]R$$

SVD分解  $E = U\text{diag}(1,1,0)V^T$

## 本质矩阵分解

$$E = [T_{\times}]R$$

$$\begin{aligned} [T_{\times}] &= UZU^T \\ &= U\text{diag}(1,1,0)WU^T \\ &= U\text{diag}(1,1,0)W^T U^T \end{aligned}$$

$$\begin{aligned} E = [T_{\times}]R &= (U\text{diag}(1,1,0)WU^T)R \\ &= U\text{diag}(1,1,0)(WU^T R) \end{aligned}$$

比较



$$V^T = WU^T R$$

SVD分解  $E = U\text{diag}(1,1,0)V^T$



$$R = UW^T V^T$$

同理:

$$R = UWV^T$$

# 本质矩阵分解

$$R = UWV^T \text{ or } UW^TV^T$$

注意:  $E$  的这个因式分解只保证了矩阵  $UWV^T$  或  $UW^TV^T$  是正交的。其为旋转矩阵还需确保行列式的值为正:

$$R = (\det UWV^T)UWV^T \text{ 或 } (\det UW^TV^T)UW^TV^T$$

$$T \times T = [T_{\times}]T = UZU^TT = 0$$




$$T = \pm u_3 \text{ (} U \text{的第三列)}$$

# 本质矩阵分解

四种潜在  $R, T$  对:

$$\begin{cases} R = (\det UWV^T)UWV^T & T = u_3 \\ R = (\det UWV^T)UWV^T & T = -u_3 \\ R = (\det UW^TV^T)UW^TV^T & T = u_3 \\ R = (\det UW^TV^T)UW^TV^T & T = -u_3 \end{cases}$$



(图片来自于 Hartley and Zisserman 书第 260 页)

- 选择一个点三角化, 正确的一组解能保证该点在两个摄像机的z坐标均为正。
- 对多个点进行三角化, 选择在两个摄像机系下z坐标均为正的个数最多的那组  $R, T$ 。(更鲁棒)

## 本质矩阵分解（总结）

步骤1: SVD分解  $E = U \text{diag}(1,1,0) V^T$

$$W = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

步骤2:  $R = (\det UWV^T)UWV^T$  或  $(\det UW^TV^T)UW^TV^T$

$$T = \pm u_3$$

步骤3:

$$\begin{cases} R = (\det UWV^T)UWV^T & T = u_3 \\ R = (\det UWV^T)UWV^T & T = -u_3 \\ R = (\det UW^TV^T)UW^TV^T & T = u_3 \\ R = (\det UW^TV^T)UW^TV^T & T = -u_3 \end{cases}$$

步骤4: 通过重建单个或多个点找出正确解

## 欧式结构恢复（2视图）

问题:

$$x_{1j} = M_1 X_j = K_1 [I \quad 0] X_j$$

$$j = 1 \dots, n$$

$$x_{2j} = M_2 X_j = K_2 [R \quad T] X_j$$

求解: 1. 求解基础矩阵F

归一化八点法

2. 利用F与摄像机内参数求解本质矩阵E

$$E = K_2^T F K_1$$

3. 分解本质矩阵获得R与T

$$E \rightarrow R, T \rightarrow M_2$$

4. 三角化求解三维点 $X_j$ 坐标

$$X_j^* = \underset{X_j}{\operatorname{argmin}} (d(x_{1j}, M_1 X_j) + d(x_{2j}, M_2 X_j))$$

## 欧式结构恢复歧义

---

- 例子：仅凭下图能否估计场景的绝对尺度？



## 欧式结构恢复歧义

---

- 例子：仅凭下图能否估计场景的绝对尺度？

显然不能！





## 欧式结构恢复歧义


- 例子：仅凭下图能否估计场景的绝对尺度？

需要其他先验信息！




## 欧式结构恢复歧义

- 恢复出来的欧式结构与真实场景之间相差一个相似变换（旋转，平移，缩放）
- 恢复的场景与真实场景之间仅存在相似变换的重构称为**度量重构**



## 欧式结构恢复歧义

---



R. Hartley and A. Zisserman, Multiple View Geometry in Computer Vision, 2nd edition, 2003

## 今日主题

---

- 运动恢复结构问题
- 欧式结构恢复
- 仿射结构恢复
- 透视结构恢复

# 仿射摄像机

透视

$$x = MX = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} X = \begin{bmatrix} m_1 X \\ m_2 X \\ m_3 X \end{bmatrix} \quad M = \begin{bmatrix} A & b \\ v & 1 \end{bmatrix} = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix}$$

$$x^E = \left( \frac{m_1 X}{m_3 X}, \frac{m_2 X}{m_3 X} \right)^T$$

仿射

$$x = MX = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} X \quad M = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} A_{2 \times 3} & b_{2 \times 1} \\ 0_{1 \times 3} & 1 \end{bmatrix} = \begin{bmatrix} m_1 & & \\ m_2 & & \\ 0 & 0 & 1 \end{bmatrix}$$

$$m_3 X = 1$$

$$x^E = (m_1 X, m_2 X)^T = [A \ b] X = \begin{bmatrix} A & b \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = AX^E + b$$

↑      ↑  
放大率

$$X^E = \begin{bmatrix} x \\ y \\ z \end{bmatrix}$$

# 仿射结构恢复问题


**问题：**已知n个三维点 $X_j (j = 1, \dots, n)$ 在m张图像中的对应点的像素坐标 $x_{ij}$

**问题：**公式中且  $x_{ij} = A_i X_j + b_i \quad i = 1, \dots, \boxed{m}; \quad j = 1, \dots, \boxed{n}$   
各个元素的维  
度？  
↑      ↑  
图像个数      3D点个数

其中， $A_i, b_i$  组成了第i张图片对应的仿射摄像机的投影矩阵  $M_i = \begin{bmatrix} A_i & b_i \\ 0 & 1 \end{bmatrix}$

**求解：**

- n个三维点 $X_j (j = 1, \dots, n)$ 的坐标
- m个仿射摄像机的投影矩阵 $A_i$ 与 $b_i (i = 1, \dots, m)$



## 仿射结构恢复问题

---

两种方法:

- 代数方法
- 因式分解法

## 仿射结构恢复问题

---

两种方法:

-代数方法

-因式分解法


- 数据中心化
- 因式分解

# 数据中心化

中心化：减去图像点的质心

$$\hat{x}_{ij} = x_{ij} - \bar{x}_i \quad \bar{x}_i = \frac{1}{n} \sum_{k=1}^n x_{ik} \quad x_{ij} = A_i X_j + b_i$$

$$\hat{x}_{ij} = x_{ij} - \frac{1}{n} \sum_{k=1}^n x_{ik} = A_i X_j + b_i - \frac{1}{n} \sum_{k=1}^n A_i X_k - \frac{1}{n} \sum_{k=1}^n b_i$$



$$= A_i \left( X_j - \frac{1}{n} \sum_{k=1}^n X_k \right) = A_i (X_j - \bar{X}) = A_i \hat{X}_j$$

$$\hat{x}_{ij} = A_i \hat{X}_j = A_i X_j$$

如果3D点的质心 = 世界坐标系的中心

## 因式分解

把去均值以后的  $m \times n$  个测量值写成矩阵的形式：

$$D = \begin{bmatrix} \hat{x}_{11} & \hat{x}_{12} & \cdots & \hat{x}_{1n} \\ \hat{x}_{21} & \hat{x}_{22} & \cdots & \hat{x}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{m1} & \hat{x}_{m2} & \cdots & \hat{x}_{mn} \end{bmatrix} \quad \begin{matrix} \text{---} n \text{---} \\ \text{---} (2m) \text{---} \end{matrix}$$

每个  $\hat{x}_{ij}$  是一个  $2 \times 1$  向量！

## 因式分解

$2m \times n$  维的数据(测量值)矩阵:

$$D = \begin{bmatrix} \hat{x}_{11} & \hat{x}_{12} & \cdots & \hat{x}_{1n} \\ \hat{x}_{21} & \hat{x}_{22} & \cdots & \hat{x}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{m1} & \hat{x}_{m2} & \cdots & \hat{x}_{mn} \end{bmatrix} = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_m \end{bmatrix} \begin{bmatrix} X_1 & X_2 & \cdots & X_n \end{bmatrix}$$


$(2m \times n)$       摄像机  $M$   $(2m \times 3)$       点  $(3 \times n)$        $S$

$A_i$  是  $2 \times 3$  维,  $X_j$  是  $3 \times 1$  维

测量矩阵  $D = MS$  秩为3 (它是  $2m \times 3$  矩阵和  $3 \times n$  矩阵的乘积)


## 因式分解

怎么分解D?




## 因式分解

- 通过计算D的奇异值分解！




## 因式分解


由于  $\text{rank}(D)=3$ , 理想情况下这里只有三个非零的奇异值  $\sigma_1, \sigma_2$  和  $\sigma_3$



## 因式分解



## 求解运动与结构



$$D = U_3 W_3 V_3^T = U_3 (W_3 V_3^T) = MS$$



# 仿射结构恢复问题

**问题：**已知 $n$ 个三维点 $X_j (j = 1, \dots, n)$  在 $m$ 张图像中的对应点的像素坐标 $x_{ij}$

**求解：**

- $n$ 个三维点 $X_j (j = 1, \dots, n)$ 的坐标
- $m$ 个投影矩阵 $M_i$  (即 $A_i$ 与 $b_i$ ) ( $i = 1, \dots, m$ )

计算步骤：


1. 创建一个  $2m \times n$  维的数据(测量值)矩阵 $D$

2. 分解矩阵 $D = U_3 W_3 V_3^T$ ,  $M = U_3$ 及 $S = W_3 V_3^T$

$$D = \begin{bmatrix} \hat{x}_{11} & \hat{x}_{12} & \dots & \hat{x}_{1n} \\ \hat{x}_{21} & \hat{x}_{22} & \dots & \hat{x}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{m1} & \hat{x}_{m2} & \dots & \hat{x}_{mn} \end{bmatrix} = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_m \end{bmatrix} \begin{bmatrix} X_1 & X_2 & \dots & X_n \end{bmatrix}$$

$(2m \times n)$       摄像机  $M$   $(2m \times 3)$       点  $(3 \times n)$

问题：这样分解可以吗？



$$D = U_3 W_3 V_3^T = (U_3 W_3) V_3^T = M^* S^*$$

## 仿射结构恢复歧义

$$\mathbf{D} = \mathbf{M} \mathbf{H} \times \mathbf{H}^{-1} \mathbf{S}$$

## 仿射结构恢复歧义

$$\mathbf{D} = \underbrace{\mathbf{M} \mathbf{H}}_{\mathbf{M}^*} \times \underbrace{\mathbf{H}^{-1} \mathbf{S}}_{\mathbf{S}^*}$$

- 分解不唯一。通过以下变换可以得到相同的D:

$$\mathbf{M}^* = \mathbf{M} \mathbf{H}$$

$$\mathbf{S}^* = \mathbf{H}^{-1} \mathbf{S}$$

其中  $\mathbf{H}$  是任意可逆的  $3 \times 3$  矩阵

- 必须利用其他约束条件来解决歧义

## 仿射结构恢复问题

**问题：**已知 $n$ 个三维点 $X_j (j = 1, \dots, n)$  在 $m$ 张图像中的对应点的像素坐标 $x_{ij}$

**求解：**

- $n$ 个三维点 $X_j (j = 1, \dots, n)$ 的坐标
- $m$ 个投影矩阵 $M_i$  (即 $A_i$ 与 $b_i$ ) ( $i = 1, \dots, m$ )

**问题：**给定 $m$ 个相机， $n$ 个三维点，我们有多少个等式，多少个未知量？

**回答：** $2mn$ 个等式， $8m+3n-8$ 个未知量

**计算步骤：**


1. 创建一个  $2m \times n$  维的数据(测量值)矩阵 $D$

2. 分解矩阵 $D = U_3 W_3 V_3^T$ ,  $M = U_3$ 及 $S = W_3 V_3^T$

$$D = \begin{bmatrix} \hat{x}_{11} & \hat{x}_{12} & \dots & \hat{x}_{1n} \\ \hat{x}_{21} & \hat{x}_{22} & \dots & \hat{x}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{m1} & \hat{x}_{m2} & \dots & \hat{x}_{mn} \end{bmatrix} = \begin{bmatrix} A_1 \\ A_2 \\ \vdots \\ A_m \end{bmatrix} \begin{bmatrix} X_1 & X_2 & \dots & X_n \end{bmatrix}$$


$(2m \times n)$       摄像机  $M$   $(2m \times 3)$       点  $(3 \times n)$

## 仿射结构恢复歧义



## 仿射结构恢复歧义

---



R. Hartley and A. Zisserman, Multiple View Geometry in Computer Vision, 2nd edition, 2003

## 今日主题

---

- 运动恢复结构问题
- 欧式结构恢复
- 仿射结构恢复
- 透视结构恢复

# 透视摄像机

透视

$$x = MX = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} X = \begin{bmatrix} m_1 X \\ m_2 X \\ m_3 X \end{bmatrix} \quad M = \begin{bmatrix} A & b \\ v & 1 \end{bmatrix} = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & b_1 \\ a_{21} & a_{22} & a_{23} & b_2 \\ a_{31} & a_{32} & a_{33} & 1 \end{bmatrix}$$

$$x^E = \left( \frac{m_1 X}{m_3 X}, \frac{m_2 X}{m_3 X} \right)^T$$

仿射

$$x = MX = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} X \quad M = \begin{bmatrix} m_1 \\ m_2 \\ m_3 \end{bmatrix} = \begin{bmatrix} A_{2 \times 3} & b_{2 \times 1} \\ 0_{1 \times 3} & 1 \end{bmatrix} = \begin{bmatrix} m_1 & & & \\ m_2 & & & \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

$$x^E = (m_1 X, m_2 X)^T = [A \ b] X = [A \ b] \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = AX^E + b$$

↑ ↑  
放大率

$$X^E = \begin{bmatrix} x \\ y \\ z \end{bmatrix}$$

# 透视结构恢复问题

**问题：**已知n个三维点 $X_j$  ( $j = 1, \dots, n$ )在m张图像中的对应点的像素坐标 $x_{ij}$ ;


且  $x_{ij} = M_i X_j \quad i = 1, \dots, m; j = 1, \dots, n$

↑ ↑  
图像个数      3D点个数


其中,  $M_i$  为第i张图片对应的摄像机的投影矩阵

**求解：**


- n个三维点 $X_j$  ( $j = 1, \dots, n$ )的坐标;
- m个摄像机投影矩阵 $M_i$  ( $i = 1, \dots, m$ )。



## 透视结构恢复歧义




## 透视结构恢复歧义



## 透视结构恢复歧义

---



R. Hartley and A. Zisserman, Multiple View Geometry in Computer Vision, 2nd edition, 2003

## 透视结构恢复方法

---

在相差一个 $4 \times 4$ 的可逆变换的情况下恢复摄像机运动与场景结构

- 代数方法（通过基础矩阵）
- 因式分解法（通过SVD）
- 捆绑调整

# 透视结构恢复方法


在相差一个 $4 \times 4$ 的可逆变换的情况下恢复摄像机运动与场景结构

- 代数方法 (通过基础矩阵)

- 因式分解法 (通过SVD)

- 捆绑调整

## 代数方法 (两视图情况)






## 代数方法(两视图情况)

1. 求解基础矩阵 F  
归一化八点法
2. 利用 F 估计摄像机矩阵  
 $F \rightarrow M_1, M_2$
3. 三角化计算三维点坐标


$$X_j^* = \underset{X_j}{\operatorname{argmin}} (d(x_{1j}, M_1 X_j) + d(x_{2j}, M_2 X_j))$$

$$x_{1j} = M_1 X_j$$

$$x_{2j} = M_2 X_j$$



## 利用 F 估计摄像机矩阵



$$x_{1j} = M_1 X_j$$

$$x_{2j} = M_2 X_j$$

$$j = 1 \dots, n$$

↑  
3D点个数

由于透视歧义存在，我们总是可以找到一个可逆矩阵 H，使得：

$$M_1 H^{-1} = [I|0]$$

$$M_2 H^{-1} = [A|b]$$

## 利用 F 估计摄像机矩阵

- $X$  表示3D点
- 将  $x$  和  $x'$  分别称为摄像机1和2的对应观测值

$$\begin{cases} \tilde{M}_1 = M_1 H^{-1} = [I & 0] & x = M_1 X = M_1 H^{-1} H X = [I|0] \tilde{X} \\ \tilde{M}_2 = M_2 H^{-1} = [A & b] & x' = M_2 X = M_2 H^{-1} H X = [A|b] \tilde{X} \\ \tilde{X} = H X \end{cases}$$

$$x' = [A|b] \tilde{X} = [A|b] \begin{bmatrix} \tilde{X}_1 \\ \tilde{X}_2 \\ \tilde{X}_3 \\ 1 \end{bmatrix} = A[I|0] \begin{bmatrix} \tilde{X}_1 \\ \tilde{X}_2 \\ \tilde{X}_3 \\ 1 \end{bmatrix} + b = A[I|0] \tilde{X} + b = Ax + b$$

$$x' \times b = (Ax + b) \times b = Ax \times b$$

$$F = [b_{\times}] A$$

$$x'^T \cdot (x' \times b) = x'^T \cdot (Ax \times b) = 0$$

$$x'^T F x = 0$$

$$x'^T (b \times Ax) = 0 \implies x'^T [b_{\times}] A x = 0$$

基本矩阵!

## 利用 F 估计摄像机矩阵

$$\text{已知: } x'^T F x = 0 \quad F = [b_{\times}] A$$

## 利用 F 估计摄像机矩阵

$$\text{已知: } x'^T F x = 0 \quad F = [b_{\times}] A$$

1. 计算b:

➤ 考虑乘积  $F^T b$

$$F^T \cdot b = ([b_{\times}] A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$$

## 利用 F 估计摄像机矩阵

$$\text{已知: } x'^T F x = 0 \quad F = [b_{\times}] A$$

1. 计算b:

➤ 考虑乘积  $F^T b$

$$F^T \cdot b = ([b_{\times}] A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$$

$$F^T b = 0$$

## 利用 F 估计摄像机矩阵

已知:  $x'^T F x = 0$   $F = [b_{\times}]A$

1. 计算b:

- 考虑乘积  $F^T b$   $F^T \cdot b = ([b_{\times}]A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$   $F^T b = 0$
- $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

## 利用 F 估计摄像机矩阵

已知:  $x'^T F x = 0$   $F = [b_{\times}]A$

1. 计算b:

- 考虑乘积  $F^T b$   $F^T \cdot b = ([b_{\times}]A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$   $F^T b = 0$
- $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

2. 计算 A:

- 定义:  $A' = -[b_{\times}]F$
- 验证  $[b_{\times}]A'$  等于  $F$  :

## 利用 F 估计摄像机矩阵

$$\text{已知: } x'^T F x = 0 \quad F = [b_{\times}] A$$

### 1. 计算b:

- 考虑乘积  $F^T b$   $F^T \cdot b = ([b_{\times}] A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$   $F^T b = 0$
- $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

### 2. 计算 A:

- 定义:  $A' = -[b_{\times}] F$
- 验证  $[b_{\times}] A'$  等于  $F$  :

$$[b_{\times}] A' = -[b_{\times}] [b_{\times}] F = -(bb^T - |b|^2 I) F = -b b^T F + |b|^2 F = 0 + 1 \cdot F = F$$

## 利用 F 估计摄像机矩阵

$$\text{已知: } x'^T F x = 0 \quad F = [b_{\times}] A$$

### 1. 计算b:

- 考虑乘积  $F^T b$   $F^T \cdot b = ([b_{\times}] A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$   $F^T b = 0$
- $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

### 2. 计算 A:

- 定义:  $A' = -[b_{\times}] F$
- 验证  $[b_{\times}] A'$  等于  $F$  :

$$[b_{\times}] A' = -[b_{\times}] [b_{\times}] F = -(bb^T - |b|^2 I) F = -b b^T F + |b|^2 F = 0 + 1 \cdot F = F$$

- 因此,  $A = A' = -[b_{\times}] F$

## 利用 F 估计摄像机矩阵

已知:  $x'^T F x = 0$        $F = [b_{\times}]A$

### 1. 计算b:

➤ 考虑乘积  $F^T b$        $F^T \cdot b = ([b_{\times}]A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$        $F^T b = 0$

➤  $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

### 2. 计算 A:

• 定义:  $A' = -[b_{\times}]F$

• 验证  $[b_{\times}]A'$  等于  $F$  :

$$[b_{\times}]A' = -[b_{\times}][b_{\times}]F = -(bb^T - |b|^2 I)F = -bb^T F + |b|^2 F = 0 + 1 \cdot F = F$$

• 因此,  $A = A' = -[b_{\times}]F$

摄像机矩阵:       $\tilde{M}_1 = [I \ 0]$        $\tilde{M}_2 = [-[b_{\times}]F \ b]$

## 利用 F 估计摄像机矩阵

已知:  $x'^T F x = 0$        $F = [b_{\times}]A$

问题: 这里  $b$  是什么?

### 1. 计算b:

➤ 考虑乘积  $F^T b$        $F^T \cdot b = ([b_{\times}]A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$        $F^T b = 0$

➤  $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

### 2. 计算 A:

• 定义:  $A' = -[b_{\times}]F$

• 验证  $[b_{\times}]A'$  等于  $F$  :


$$[b_{\times}]A' = -[b_{\times}][b_{\times}]F = -(bb^T - |b|^2 I)F = -bb^T F + |b|^2 F = 0 + 1 \cdot F = F$$

• 因此,  $A = A' = -[b_{\times}]F$

摄像机矩阵:       $\tilde{M}_1 = [I \ 0]$        $\tilde{M}_2 = [-[b_{\times}]F \ b]$

## 极几何约束

$$p'^T F p = 0$$



- $l = F^T p'$  是  $p'$  对应的极线
- $l' = F p$  是  $p$  对应的极线
- $F e = 0, F^T e' = 0$
- $F$  是奇异的(秩2)
- $F$  的DOF为7

## 利用 $F$ 估计摄像机矩阵

已知:  $x'^T F x = 0 \quad F = [b_{\times}] A$

问题: 这里  $b$  是什么?

回答:  $b$  是一个极点

1. 计算  $b$ :

➤ 考虑乘积  $F^T b$   $F^T \cdot b = ([b_{\times}] A)^T \cdot b = A^T [b_{\times}]^T \cdot b = -A^T [b_{\times}] \cdot b = 0$

$$F^T b = 0$$

➤  $b$  为  $F^T$  矩阵最小奇异值的右奇异向量, 且  $\|b\| = 1$

2. 计算  $A$ :

• 定义:  $A' = -[b_{\times}] F$

• 验证  $[b_{\times}] A'$  等于  $F$ :

$$[b_{\times}] A' = -[b_{\times}] [b_{\times}] F = -(b b^T - |b|^2 I) F = -b b^T F + |b|^2 F = 0 + 1 \cdot F = F$$

• 因此,  $A = A' = -[b_{\times}] F$

摄像机矩阵:  $\tilde{M}_1 = [I \ 0] \quad \tilde{M}_2 = [-[b_{\times}] F \ b]$

## 代数方法(两视图情况)

1. 求解基础矩阵  $F$


归一化八点法

2. 利用  $F$  估计摄像机矩阵

$$\tilde{M}_1 = [I \ 0] \quad \tilde{M}_2 = [-[b_x]F \ b]$$

3. 三角化计算三维点坐标


$$X_j^* = \underset{X_j}{\operatorname{argmin}} (d(x_{1j}, M_1 X_j) + d(x_{2j}, M_2 X_j))$$



$$x_{1j} = M_1 X_j$$

$$x_{2j} = M_2 X_j$$

## 代数方法( $N$ 视图情况)



分别对每一个图像对  $I_k$  与  $I_h$  计算运动与结构

$$I_k \text{ 与 } I_h \rightarrow \tilde{M}_k, \tilde{M}_h, \tilde{X}_{[k,h]}$$

**增量法!**



## 透视结构恢复方法

- 代数方法（通过基础矩阵）
- 因式分解法(通过SVD)

- 捆绑调整

## 代数法与分解法的局限性

- **因式分解法**假定所有点都是可见的，所以下述场合不可用：

- 存在遮挡
- 建立对应点关系失败

能够用于构建观测矩阵D的点少，重建点数少！

- **代数法**应用于2视图重建


易出现误差累积！

$$D = \begin{bmatrix} \hat{x}_{11} & \hat{x}_{12} & \cdots & \hat{x}_{1n} \\ \hat{x}_{21} & \hat{x}_{22} & \cdots & \hat{x}_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{m1} & \hat{x}_{m2} & \cdots & \hat{x}_{mn} \end{bmatrix}$$

## 捆绑调整

- 恢复结构和运动的非线性方法

最小化重投影误差: 
$$E(M, X) = \sum_{i=1}^m \sum_{j=1}^n D(x_{ij}, M_i X_j)^2$$



## 捆绑调整

$$E(M, X) = \sum_{i=1}^m \sum_{j=1}^n D(x_{ij}, M_i X_j)^2$$

非线性最小化问题
测量值
参数

- 牛顿法 与 列文伯格-马夸尔特法 (L-M方法)

## 捆绑调整

$$E(M, X) = \sum_{i=1}^m \sum_{j=1}^n D(x_{ij}, M_i X_j)^2$$

非线性最小化问题

测量值      参数

- 牛顿法 与 列文伯格-马夸尔特法 (L-M方法)

### 优势

- 同时处理大量视图
- 处理丢失的数据

## 捆绑调整

$$E(M, X) = \sum_{i=1}^m \sum_{j=1}^n D(x_{ij}, M_i X_j)^2$$

非线性最小化问题

测量值      参数

- 牛顿法 与 列文伯格-马夸尔特法 (L-M方法)

### 优势

- 同时处理大量视图
- 处理丢失的数据

### 局限性

- 大量参数的最小化问题
- 需要良好的初始条件

## 捆绑调整

$$E(M, X) = \sum_{i=1}^m \sum_{j=1}^n D(x_{ij}, M_i X_j)^2$$

非线性最小化问题

测量值      参数

- 牛顿法 与 列文伯格-马夸尔特法 (L-M方法)

### 优势

- 同时处理大量视图
- 处理丢失的数据

### 局限性

- 大量参数的最小化问题
- 需要良好的初始条件

### 实际操作:

- 常用作SFM的最后一步，分解或代数方法可作为优化问题的初始解

## 今日主题

- 运动恢复结构问题 (完)
- 欧式结构恢复 (完)
- 仿射结构恢复 (完)
- 透视结构恢复 (完)